


Componentes Principales

Interés: Reducir dimensiones (variables) en un problema

1

¿Qué es reducir dimensiones?



2

¿Cómo se representan las dimensiones?

X_1, \dots, X_p vectores de \mathbb{R}^n

$\mathfrak{R}\{X_1, \dots, X_p\}$ sub espacio vectorial
generado por la familia

Dimensión:


número máximo de vectores
linealmente independientes en
el espacio o sub espacio
vectorial

Con la base se
identifican los
elementos del
espacio mediante
sus coordenadas
relativas a una
base

3

Caso $p = 2$ Proyecciones ortogonales)

$$P \in \mathfrak{R}\{X_1, \dots, X_p\}$$





$$P = a e_1 + b e_2$$

$$P = a_1 u_1 + b_1 u_2$$

4

Entonces ¿Qué es una proyección (ortogonal)?



5

Los datos

Variables a analizar en el problema:

$$\mathbb{X} = (X_1, \dots, X_p)^t$$


Matriz de datos:

$$X = (x_{ij})_{n,p} = \begin{bmatrix} x_{11} \\ \vdots \\ x_{n1} \end{bmatrix}$$

Muestra aleatoria de \mathbb{X}

$$(x_i)_{i=1, \dots, n}$$

Nube de puntos (datos)




6

Idea:


Proyectar la nube de puntos en un subespacio vectorial centrado en una posición conveniente (espacio afín) con una dimensión menor.

Deformando la nube lo menos posible




7

Componentes principales



Una propiedad importante de la proyección




8

Idea:

Proyectar la nube de puntos en un subespacio vectorial centrado en una posición conveniente (espacio afín) con una dimensión menor.

Deformando la nube lo menos posible




Para medir la forma (dispersión) de la nube (N) se utiliza la inercia

$\bar{\mathbb{X}}$: centro de masa

$$I_g(N) = E((\mathbb{X} - g)^t(\mathbb{X} - g))$$

momento de inercia relativo al punto g

9



Teorema de Huygens

$$I_g(N) \geq I_{\bar{\mathbb{X}}}(N) = \Sigma_{\mathbb{X}}$$

Poniendo el centro en $\bar{\mathbb{X}}$, la nube de puntos tiene la menor deformación

La inercia es mínima

10



La matriz de varianzas y covarianzas mide la inercia y representa la información contenida en los datos (sus diferencias, semejanzas y relaciones)

11


¿Cómo encontrar la base y reducir las dimensiones?

12

Idea:

Proyectar la nube de puntos en un subespacio vectorial centrado en una posición conveniente (espacio afín) con una dimensión menor.

Deformando la nube lo menos posible




13

Idea:


Proyectar la nube de puntos en un subespacio vectorial centrado en una posición conveniente (espacio afín) con una dimensión menor.

Deformando la nube lo menos posible



14

Proyecciones



Observe que (de nuevo)

$$\underline{\underline{X}} = g + \lambda_1 U_1 + \lambda_2 U_2$$

En general se busca una base $(U_i)_{i=1,..,n}$

tal que la nube proyectada se descomponga en:

$$\bar{X} + \mathcal{R}\{U_1, \dots, U_q\}$$

Nuestro punto de partida

$$\mathbb{X} = (X_1, \dots, X_p)^t$$

$\Sigma_{\mathbb{X}}$ definida positiva

Valores propios: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$

Vectores propios: V_1, V_2, \dots, V_p

Recuerde que, para cada i :

$$\Sigma_{\mathbb{X}} V_i = \lambda_i V_i$$

Cuando las escalas de medición son muy diferentes se trabaja con variables estandarizadas y entonces

$$\Sigma_{\mathbb{X}}$$


Es igual a la matriz de correlaciones

15

Idea:

Proyectar la nube de puntos en un subespacio vectorial centrado en una posición conveniente (espacio afín) con una dimensión menor.

Deformando la nube lo menos posible




Cada componente (las coordenadas que determinan en cada eje) deben tener la mayor variabilidad posible (eso representa información): Varianza máxima


Primera componente:

$$\begin{aligned} \text{Tomando: } \|V_1\| &= 1 \\ Y_1 &= V_1^t \mathbb{X} \\ \text{var}(Y_1) &= \lambda_1 \end{aligned}$$


Primer eje principal



16



Representación del individuo i (su proyección)
en el 1er. plano principal [Y1, Y2]



Primera
componente:

Tomando: $\| V_1 \| = 1$
 $Y_1 = V_1^t \mathbb{X}$
 $var(Y_1) = \lambda_1$

Segunda
componente:

Tomando: $\| V_2 \| = 1$
 $Y_2 = V_2^t \mathbb{X}$
 $var(Y_2) = \lambda_2$
 $cov(Y_1, Y_2) = 0$

17

En resumen se tiene:

(1) Las variables originales

$$\mathbb{X} = (X_1, \dots, X_p)^t$$

(2) Las nuevas variables

$$\mathbb{Y} = (Y_1, \dots, Y_q)^t \quad (q \leq p)$$

$$\text{con } Y_i = V_i^t \mathbb{X}$$

Que representan las coordenadas en
un nuevo espacio donde se pueden
representar los individuos

**Las componentes principales
son vectores ortogonales**

Primera
componente:

Tomando: $\| V_1 \| = 1$
 $Y_1 = V_1^t \mathbb{X}$
 $var(Y_1) = \lambda_1$

Segunda
componente:

Tomando: $\| V_2 \| = 1$
 $Y_2 = V_2^t \mathbb{X}$
 $var(Y_2) = \lambda_2$
 $cov(Y_1, Y_2) = 0$

Componente
i:

Tomando: $\| V_i \| = 1$
 $Y_i = V_i^t \mathbb{X}$
 $var(Y_i) = \lambda_i$
 Para $j < i$ (los anteriores):
 $cov(Y_i, Y_j) = 0$

18

Obtención de las componentes y las variables

19

Se desea analizar los resultados en 6 exámenes (valor de 0 a 10) de un grupo de 10 estudiantes.

- (a) Caracterizar su desempeño
- (b) Valorar la importancia de los exámenes en el contexto de los resultados
- (c) Identificar si se observan semejanzas o diferencias entre estudiantes.
- (d) ¿Se podrá hacer la caracterización utilizando un conjunto menor de variables? En ese caso ¿qué significarían?

Archivo: examenes

```
> Ex
      mat fis esp hist ef
Lucia  7.0 6.5 9.2  8.6 8.0
Pedro  7.5 9.4 7.3  7.0 7.0
Ines   7.6 9.2 8.0  8.0 7.5
Luis   5.0 6.5 6.5  7.0 9.0
Andres 6.0 6.0 7.8  8.9 7.3
Ana    7.8 9.6 7.7  8.0 6.5
Carlos 6.3 6.4 8.2  9.0 7.2
Jose   7.9 9.7 7.5  8.0 6.0
Sonia  6.0 6.0 6.5  5.5 8.7
Maria  6.8 7.2 8.7  9.0 7.0
```

20

Paso 1: Obtener las CP

Variables estandarizadas porque es lo más general

```

> #paquete FactoMineR
> library(FactoMineR)
>
> #obtención de las CP y las depositos
> #en un objeto
>
> CP_Ex=PCA(Ex,scale.unit=TRUE,ncp=5,graph=FALSE)
>
> #cuando se estandarizan las variables scale.unit=TRUE
> #ncp: número de componentes a analizar

```

Paso 2: Para los análisis utilizar el paquete factoextra

```

#para analizar se utiliza el
#paquete factoextra

library(factoextra)

```

21

```

> #Las variables
> #la funcion get_pca_var brinda varias info
>
> var_Ex=get_pca_var(CP_Ex)
>
> #se depositan en este objeto, sus diferentes componentes
> #contienen diversos criterios
> #caso donde se obtienen las coordenadas
> #es decir, los vectores propios que constituyen
> #los coeficientes de las CP
>
> #visualizacion de las coordenadas
> var_Ex$coord

```

Obtención de las
componentes principales
(dimensiones, variables
sintéticas)

Vectores propios

```

> var_Ex$coord

```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
mat	0.8957980	-0.3452036	0.25797931	-0.09146818	0.05882803
fis	0.7227976	-0.6483946	0.02384033	0.23587773	-0.03068234
esp	0.6108931	0.7173206	0.33102532	-0.02454152	-0.04561456
hist	0.5999227	0.7484701	-0.23206345	0.15639747	0.03964443
ef	-0.9139265	0.1196373	0.34065108	0.18315368	0.02892890

22

Componentes (Vectores propios)

```
> var_Ex$coord
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
mat  0.8957980 -0.3452036  0.25797931 -0.09146818  0.05882803
fis  0.7227976 -0.6483946  0.02384033  0.23587773 -0.03068234
esp  0.6108931  0.7173206  0.33102532 -0.02454152 -0.04561456
hist 0.5999227  0.7484701 -0.23206345  0.15639747  0.03964443
ef   -0.9139265  0.1196373  0.34065108  0.18315368  0.02892890
```

Obtención de las
varianzas
respectivas
(Valores propios)

Varianzas (Valores propios)

```
> #valores propios
> vp=get_eigenvalue(CP_Ex)
> vp
      eigenvalue variance.percent cumulative.variance.percent
Dim.1 2.893249673       57.8649935          57.86499
Dim.2 1.628650425       32.5730085          90.43800
Dim.3 0.346596049        6.9319210          97.36992
Dim.4 0.122612460        2.4522492          99.82217
Dim.5 0.008891393         0.1778279         100.00000
```

23

Determinación de las
componentes
principales más
importantes
(con las que se va a
trabajar)

24

(1) Las variables originales

$$\mathbb{X} = (X_1, \dots, X_p)^t$$

$$\Sigma_{\mathbb{X}}$$

(2) Las nuevas variables

$$\mathbb{Y} = (Y_1, \dots, Y_q)^t \quad (q \leq p)$$

$$\text{var}(Y_i) = \lambda_i$$

Respecto a la variabilidad

$$\text{tr}(\Sigma_{\mathbb{X}}) = \sum_{i=1}^p \sigma_{ii} = \text{Var Total}$$

$$\text{tr}(\Sigma_{\mathbb{X}}) = \sum_{i=1}^p \text{var}(Y_i) = \sum_{i=1}^p \lambda_i$$

$$\text{Var Total} = \sum_{i=1}^p \lambda_i$$

En su conjunto las Componentes Principales representan la variabilidad total de las variables originales

25

De acá se puede caracterizar la importancia de los nuevos ejes (de las Componentes Principales)

Para $i = 1, \dots, n$

$$\text{var}(Y_i) = \lambda_i$$

$$\text{Var Total} = \sum_{i=1}^p \lambda_i$$

Varianza (inercia) explicada por una componente (un eje)

Para $i = 1, \dots, n$

$$\frac{\lambda_i}{\text{Var Total}}$$

Varianza (inercia) explicada por el plano $[Y_i, Y_j]$

Para $i, j = 1, \dots, n \quad i \neq j$

$$\frac{\lambda_i + \lambda_j}{\text{Var Total}}$$

Varianza (inercia) acumulada hasta la componente k ($\lambda_1 \geq \dots \geq \lambda_q$)

$$\frac{\sum_{i=1}^k \lambda_i}{\text{Var Total}}$$

26

No hay direcciones privilegiadas

Si para todo i: $\frac{\lambda_i}{Var\ Total} \approx \frac{1}{p}$

$$\frac{\lambda_i}{Var\ Total}$$

Tomar q que asegure: inercia acumulada sea mayor a 80% o 90%

$$\frac{\sum_{i=1}^k \lambda_i}{Var\ Total}$$

Varianza (inercia) explicada por una componente (un eje)

Varianza (inercia) acumulada hasta la componente k

```
> vp
      eigenvalue variance.percent cumulative.variance.percent
Dim.1  2.893249673      57.8649935           57.86499
Dim.2  1.628650425      32.5730085           90.43800
Dim.3  0.346596049       6.9319210           97.36992
Dim.4  0.122612460       2.4522492           99.82217
Dim.5  0.008891393       0.1778279          100.00000
```

Varianzas
(Valores
propios)

27

```
> vp
      eigenvalue variance.percent cumulative.variance.percent
Dim.1  2.893249673      57.8649935           57.86499
Dim.2  1.628650425      32.5730085           90.43800
Dim.3  0.346596049       6.9319210           97.36992
Dim.4  0.122612460       2.4522492           99.82217
Dim.5  0.008891393       0.1778279          100.00000
```

Se toman dos
ejes
principales

Otra forma de valorar la cantidad de ejes es hacer un diagrama de pendiente (SCREE)

28

#diagrama de pendiente

```
fviz_screepplot(CP_Ex,choise="eigenvalue",geom="line", ylim=c(0,100),
  xlab="dimensiones",ylab="porcentaje varianza",main="",ncp=5)
```

#ncp: numero de componentes

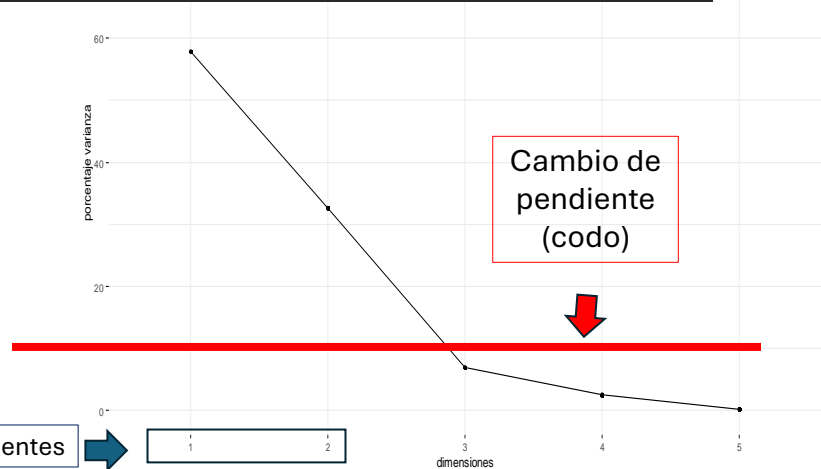
Su plano principal explica el 90.4% de la variación total



componentes



1 2



29

En resumen

30

Datos originales

```
> Ex
  mat fis esp hist ef
Lucia  7.0 6.5 9.2  8.6 8.0
Pedro  7.5 9.4 7.3   7.0 7.0
Ines   7.6 9.2 8.0   8.0 7.5
Luis   5.0 6.5 6.5   7.0 9.0
Andres 6.0 6.0 7.8   8.9 7.3
Ana    7.8 9.6 7.7   8.0 6.5
Carlos 6.3 6.4 8.2   9.0 7.2
Jose   7.9 9.7 7.5   8.0 6.0
Sonia  6.0 6.0 6.5   5.5 8.7
Maria  6.8 7.2 8.7   9.0 7.0
```

```
> var_Ex$coord
      Dim.1      Dim.2
mat  0.8957980 -0.3452036
fis  0.7227976 -0.6483946
esp  0.6108931  0.7173206
hist 0.5999227  0.7484701
ef   -0.9139265  0.1196373
```

```
> vp
      eigenvalue
Dim.1 2.893249673
Dim.2 1.628650425
```

Coordenada de Lucia en el eje 1: 14.4

Componente 1 (eje principal 1):


$$Y1 = 0.89 \cdot \text{mat} + 0.72 \cdot \text{fis} + 0.61 \cdot \text{esp} + 0.59 \cdot \text{hist} - 0.91 \cdot \text{ef}$$

Coordenada de Lucia en el eje 2: 7.36

Componente 2 (eje principal 2):

$$Y2 = -0.34 \cdot \text{mat} - 0.64 \cdot \text{fis} + 0.71 \cdot \text{esp} + 0.74 \cdot \text{hist} - 0.11 \cdot \text{ef}$$

Representación
de Lucia en el
plano principal
[Y1,Y2]
(proyección)




31

Interpretación de las
componentes (ejes)
Aporte de las variables

32


En las componentes principales los individuos se representan mediante sus coordenadas correspondientes




Para representar las variables y ver cómo influyen (se relacionan) sobre los ejes principales se utilizan las correlaciones

33

Plano principal [Y_i, Y_j]
Influencia de la variable X_k



Circulo de correlación



34

Volviendo al problema

Componente 1 (eje principal 1):

$$Y_1 = 0.89 \cdot \text{mat} + 0.72 \cdot \text{fis} + 0.61 \cdot \text{esp} + 0.59 \cdot \text{hist} - 0.91 \cdot \text{ef}$$

Componente 2 (eje principal 2):

$$Y_2 = -0.34 \cdot \text{mat} - 0.64 \cdot \text{fis} + 0.71 \cdot \text{esp} + 0.74 \cdot \text{hist} - 0.11 \cdot \text{ef}$$

$\text{cor}(\text{mat}, Y_1)$ $\text{cor}(\text{mat}, Y_2)$

```
> #diagrama circulo de correlacion
> #se retoman los objetos que se encuentran en
> #var_Ex=get_pca_var(CP_Ex)
>
> #las correlaciones se encuentran en:
> var_Ex$cor
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
mat	0.8957980	-0.3452036	0.25797931	-0.09146818	0.05882803
fis	0.7227976	-0.6483946	0.02384033	0.23587773	-0.03068234
esp	0.6108931	0.7173206	0.33102532	-0.02454152	-0.04561456
hist	0.5999227	0.7484701	0.23206345	0.15639747	0.03964443
ef	-0.9139265	0.1196373	0.34065108	0.18315368	0.02892890


Para obtener las correlaciones

35

Circulo de correlación en el problema

```
#diagrama circulo de correlacion
#se retoman los objetos que se encuentran en
#var_Ex=get_pca_var(CP_Ex)
#las correlaciones se encuentran en:
var_Ex$cor


#el gráfico
fviz_pca_var(CP_Ex, axes=c(1,2), col.var="black", col.circle="blue")
```



36

```
> var_Ex$cor
```

	Dim.1	Dim.2
mat	0.8957980	-0.3452036
fis	0.7227976	-0.6483946
esp	0.6108931	0.7173206
hist	0.5999227	0.7484701
ef	-0.9139265	0.1196373




37


Otros componentes de análisis

38

Recordando:





$$\text{cor}(X,Y) = \cos(\theta)$$



39

**Coseno del
ángulo entre
vectores**



$$[\text{cor}(X_k, Y_i)]^2 = \cos^2(\theta_{ki})$$

El cuadrado de los cosenos
permite ver cercanía a los
ejes $\cos^2(\theta_{ki}) \approx 1$ ($\theta_{ki} \approx 0$)

40

En el ejemplo

```
> #cuadrado de los cosenos
> #se retoman los objetos que se encuentran en
> #var_Ex=get_pca_var(CP_Ex)
> #los cuadrados de los cosenos se encuentran en:
>
> round(var_Ex$cos2,3)
```

$$[\text{cor}(\text{mat}, Y_1)]^2 = \cos^2(\theta_{11})$$

```
> round(var_Ex$cos2,3)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
mat	0.802	0.119	0.067	0.008	0.003
fis	0.522	0.420	0.001	0.056	0.001
esp	0.373	0.515	0.110	0.001	0.002
hist	0.360	0.560	0.054	0.024	0.002
ef	0.835	0.014	0.116	0.034	0.001

41

**Contribución de
la variable al eje
principal k
(componente Y_k)**

```
> round(var_Ex$cos2,3)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
mat	0.802	0.119	0.067	0.008	0.003
fis	0.522	0.420	0.001	0.056	0.001
esp	0.373	0.515	0.110	0.001	0.002
hist	0.360	0.560	0.054	0.024	0.002
ef	0.835	0.014	0.116	0.034	0.001

```
C[mat,Y1] = > 100*0.802/(sum(var_Ex$cos2[,1]))
[1] 27.7197
```

$C[X_k, Y_i]$: contribución variable k al eje i

$$C[X_k, Y_i] = 100 * \frac{\cos(\theta_{ik})}{\sum_{j=1}^p \cos(\theta_{ij})}$$

42

```
> #contribucion de cada variable a los ejes principales
> #se retoman los objetos que se encuentran en
> #var_Ex=get_pca_var(CP_Ex)
```

```
> round(var_Ex$cos2,3)
      Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
mat  0.802 0.119 0.067 0.008 0.003
fis  0.522 0.420 0.001 0.056 0.001
esp  0.373 0.515 0.110 0.001 0.002
hist 0.360 0.560 0.054 0.024 0.002
ef   0.835 0.014 0.116 0.034 0.001
```

```
C[mat,Y1] = > 100*0.802/(sum(var_Ex$cos2[,1]))
[1] 27.7197
```

```
> round(var_Ex$contrib,1)
      Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
mat  27.7   7.3  19.2   6.8  38.9
fis  18.1  25.8   0.2  45.4  10.6
esp  12.9  31.6  31.6   0.5  23.4
hist 12.4  34.4  15.5  19.9  17.7
ef   28.9   0.9  33.5  27.4   9.4
```

43

Los ejes y ef. Interpretación

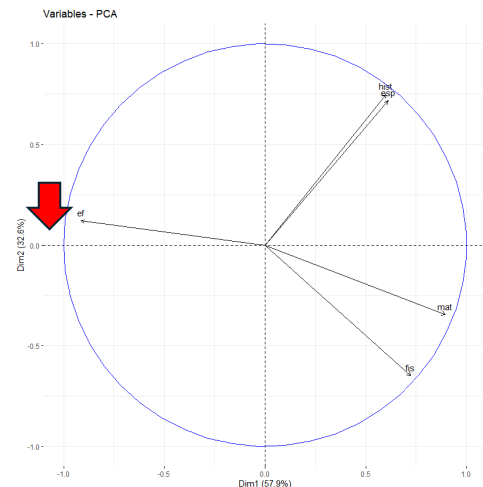
```
> round(var_Ex$cos2,3)
      Dim.1 Dim.2
mat  0.802 0.119
fis  0.522 0.420
esp  0.373 0.515
hist 0.360 0.560
ef   0.835 0.014
```

$$[\text{cor}(\text{ef}, Y_1)]^2 = \cos^2(\theta_{51})$$

$$[\text{cor}(\text{ef}, Y_2)]^2 = \cos^2(\theta_{52})$$

$C[X_k, Y_i]$: contribución variable k al eje i

```
      Dim.1 Dim.2
mat  27.7   7.3
fis  18.1  25.8
esp  12.9  31.6
hist 12.4  34.4
ef   28.9   0.9
```



```
> var_Ex$cor
      Dim.1 Dim.2
mat  0.8957980 -0.3452036
fis  0.7227976 -0.6483946
esp  0.6108931 0.7173206
hist 0.5999227 0.7484701
ef  -0.9139265 0.1196373
```

44

Resumen:

Caracterización de los ejes principales (1 y 2)

45

Componente 1 (eje principal 1):

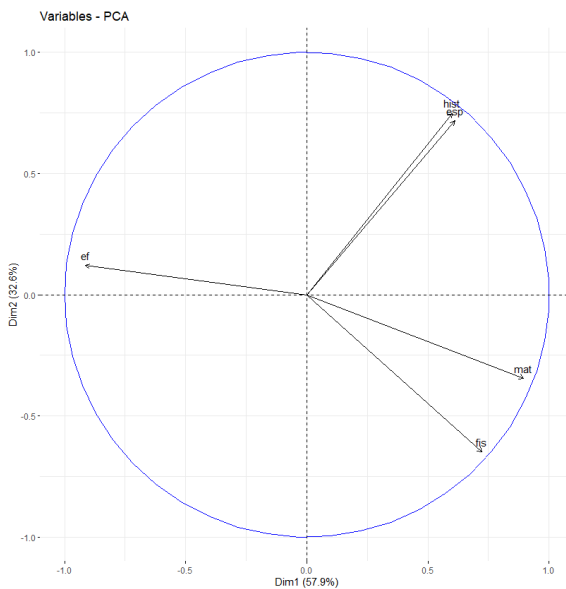
$$Y_1 = 0.89 \cdot \text{mat} + 0.72 \cdot \text{fis} + 0.61 \cdot \text{esp} + 0.59 \cdot \text{hist} - 0.91 \cdot \text{ef}$$

Varianza: 2.89 (57.8%)

Componente 2 (eje principal 2):

$$Y_2 = -0.34 \cdot \text{mat} - 0.64 \cdot \text{fis} + 0.71 \cdot \text{esp} + 0.74 \cdot \text{hist} - 0.11 \cdot \text{ef}$$

Varianza: 1.6 (32.5%)



$$[\text{cor}(Y_i, X_k)]^2 = \cos^2(\theta_{ik})$$

	Dim.1	Dim.2
mat	0.802	0.119
fis	0.522	0.420
esp	0.373	0.515
hist	0.360	0.560
ef	0.835	0.014

$C[X_k, Y_i]$: contribución variable k al eje i

	Dim.1	Dim.2
mat	27.7	7.3
fis	18.1	25.8
esp	12.9	31.6
hist	12.4	34.4
ef	28.9	0.9

46

Eje principal 1

Componente 1 (eje principal 1):

$$Y_1 = 0.89 \cdot \text{mat} + 0.72 \cdot \text{fis} + 0.61 \cdot \text{esp} + 0.59 \cdot \text{hist} - 0.91 \cdot \text{ef}$$

Varianza: 2.89 (57.8%)



$$[\text{cor}(Y_i, X_k)]^2 = \cos^2(\theta_{ik})$$

```
> cos(pi/4)^2  
[1] 0.5
```

	Dim.1	Dim.2
mat	0.802	0.119
fis	0.522	0.420
esp	0.373	0.515
hist	0.360	0.560
ef	0.835	0.014

$C[X_k, Y_i]$: contribución variable k al eje i

	Dim.1	Dim.2
mat	27.7	7.3
fis	18.1	25.8
esp	12.9	31.6
hist	12.4	34.4
ef	28.9	0.9



47

Eje principal 2

Componente 2 (eje principal 2):

$$Y_2 = -0.34 \cdot \text{mat} - 0.64 \cdot \text{fis} + 0.71 \cdot \text{esp} + 0.74 \cdot \text{hist} - 0.11 \cdot \text{ef}$$

Varianza: 1.6 (32.5%)



$$[\text{cor}(Y_i, X_k)]^2 = \cos^2(\theta_{ik})$$

```
> cos(pi/4)^2  
[1] 0.5
```

	Dim.1	Dim.2
mat	0.802	0.119
fis	0.522	0.420
esp	0.373	0.515
hist	0.360	0.560
ef	0.835	0.014

$C[X_k, Y_i]$: contribución variable k al eje i

	Dim.1	Dim.2
mat	27.7	7.3
fis	18.1	25.8
esp	12.9	31.6
hist	12.4	34.4
ef	28.9	0.9




48

En resumen:



Para la representación de individuos



49

Comportamiento de los individuos

50

```
#Para representar los individuos



#se utiliza el comando:
#este comando tiene diversas informaciones
#sobre los individuos
ind=get_pca_ind(CP_Ex)

#las coordenadas se encuentran en:
ind$coord


#para graficar los individuos
fviz_pca_ind(CP_Ex, axes=c(1,2))
```

```
> ind$coord
```

	Dim.1	Dim.2
Lucia	0.32306263	1.7725245
Pedro	0.66544057	-1.6387021
Ines	1.00254705	-0.5156925
Luis	-3.17209481	-0.2627820
Andres	-0.48886797	1.3654021
Ana	1.70863322	-1.0217004
Carlos	0.06758577	1.4623364
Jose	2.01185516	-1.2758646
Sonia	-3.04203029	-1.2548807
Maria	0.92386867	1.3693593



51



52

Un complemento, es la
calidad de la
representación de los
individuos en los ejes
(planos) principales

53

Para cada individuo hay un ángulo entre sus valores
en las variables y los ejes principales

```
> #contiene información del ángulo (coseno cuadrado)
> ind$cos2
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Lucia	0.022270827	0.670420670	0.306659839	0.0006458478	2.816992e-06
Pedro	0.139905502	0.848430539	0.006686527	0.0001680781	4.809354e-03
Ines	0.514468899	0.136122895	0.202439714	0.1365196756	1.044882e-02
Luis	0.936851990	0.006429392	0.013583605	0.0427712757	3.637375e-04
Andres	0.084139511	0.656353715	0.245603703	0.0085448999	5.358172e-03
Ana	0.732686110	0.261979570	0.004052795	0.0011209894	1.605349e-04
Carlos	0.001892733	0.886081139	0.106192189	0.0057625700	7.136907e-05
Jose	0.673612108	0.270910359	0.048916504	0.0065104446	5.058468e-05
Sonia	0.808829929	0.137636943	0.017607237	0.0358004434	1.254472e-04
Maria	0.308554271	0.677869212	0.000310977	0.0018464085	1.141913e-02

$$\cos^2(\theta_{ik}) \approx 1 \quad (\theta_{ik} \approx 0)$$

54


Para cada individuo también hay una contribución a cada uno de los ejes

```
> #tambien ind=get_pca_ind(CP_Ex)
> #contiene informacion sobre la contribucion
> #de cada individuo
> ind$contrib
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Lucia	0.36073437	19.2910834	41.46392357	0.24684974	0.01484748
Pedro	1.53049754	16.4881591	0.61060555	0.04338706	17.11987788
Ines	3.47395038	1.6328779	11.41096846	21.75259335	22.95871968
Luis	34.77814436	0.4239976	4.20932799	37.46613853	4.39379307
Andres	0.82603273	11.4470414	20.12771563	1.97950024	17.11709152
Ana	10.09047896	6.4094282	0.46591936	0.36428947	0.71941493
Carlos	0.01578791	13.1300601	7.39418080	1.13423412	0.19371414
Jose	13.98967133	9.9949649	8.48038057	3.19050613	0.34184774
Sonia	31.98461714	9.6688984	5.81215853	33.40593699	1.61421395
Maria	2.95008527	11.5134890	0.02481953	0.41656436	35.52647960

¡Inés está mal representada en el gráfico anterior!

55



Aplicación:

Ana y José se asemejan y se caracterizan por alto desempeño en mat y física, pero bajo en EF.

El eje 1 es el más importante para caracterizarlos, porque

	Dim.1	Dim.2
Lucia	0.36073437	19.2910834
Pedro	1.53049754	16.4881591
Ines	3.47395038	1.6328779
Luis	34.77814436	0.4239976
Andres	0.82603273	11.4470414
Ana	10.09047896	6.4094282
Carlos	0.01578791	13.1300601
Jose	13.98967133	9.9949649
Sonia	31.98461714	9.6688984
Maria	2.95008527	11.5134890

56